

Relatório Técnico: Quantum Machine Learning

Aplicação a Dados de Infraestrutura Espacial (NASA POWER)
Global Solution 2026.1 - FIAP

Equipe:

Octavio Augusto Ramalho Brandão Pires - RM: 555696

Guilherme Santos de Almeida - RM: 563972

1. Introdução e Contexto Espacial

A Nova Corrida Espacial transformou a órbita terrestre em um ecossistema rico em dados. Satélites e sensores geram terabytes de informações essenciais para monitoramento climático, previsão de desastres e gestão de recursos. Em resposta a este cenário, este projeto aplica **Quantum Machine Learning (QML)** na classificação de eventos climáticos anômalos, utilizando dados sintéticos baseados nas distribuições do programa **NASA POWER**.

O problema abordado conecta-se diretamente aos Objetivos de Desenvolvimento Sustentável (ODS), especificamente o **ODS 13 (Ação Contra a Mudança Global do Clima)** e **ODS 9 (Indústria, Inovação e Infraestrutura)**. A detecção precoce de anomalias climáticas a partir de séries temporais orbitais pode auxiliar no planejamento agrícola e na mitigação de desastres naturais.

2. Descrição do Dataset e Pré-processamento

O dataset utilizado é composto por dados sintéticos calibrados estatisticamente para refletir o comportamento das variáveis do NASA POWER na região da América do Sul (lat: -15°, lon: -47°) no período de 2010 a 2023. As variáveis incluem índices meteorológicos e de radiação solar.

Para garantir o treinamento correto dos algoritmos híbridos (quântico-clássicos) e evitar vazamento de dados (*data leakage*), implementamos um pipeline de pré-processamento rigoroso aplicado primeiramente ao conjunto de treino e posteriormente estendido ao teste:

- **Divisão Treino/Teste:** Particionamento da base para validação.
- **Balanceamento:** Uso do algoritmo SMOTE exclusivamente nos dados de treino para lidar com o desbalanceamento das anomalias climáticas.
- **Normalização:** O `MinMaxScaler` redimensionou as features para o intervalo $[-\pi, \pi]$, exigência técnica para o correto mapeamento quântico (angle encoding/feature map).
- **Redução de Dimensionalidade (PCA):** O número de variáveis foi reduzido para coincidir com a quantidade de qubits disponíveis (N_QUBITS), retraindo as características mais relevantes.




Figura 1: Pipeline de Pré-processamento e Integração Quântica.

3. Implementação QML

Desenvolvemos as simulações no framework **Qiskit 1.x** utilizando o Qiskit Aer. Dois modelos quânticos foram propostos:

- **Quantum Support Vector Classifier (QSVC):** Utilizou um FidelityQuantumKernel baseado no ZZFeatureMap. Este feature map é ideal para introduzir não-linearidade através de emaranhamento quântico local, capturando correlações complexas nos dados espaciais.
- **Variational Quantum Classifier (VQC):** Construído com um ansatz RealAmplitudes e otimizado através de métodos variacionais (como COBYLA).

Devido às limitações atuais de custo computacional em simulação e em hardwares da era NISQ (*Noisy Intermediate-Scale Quantum*), o treinamento foi restrito a um subconjunto de amostras reduzido (aprox. 400 instâncias).

4. Benchmarking e Métricas

Para avaliar a vantagem quântica ou as eventuais desvantagens no estágio atual da tecnologia, os modelos QML foram comparados a baselines clássicos maduros (SVM com kernel RBF e Random Forest), sob o mesmo regime de dados e features reduzidas pelo PCA.

Modelo	Tipo	AUC-ROC	F1-Score	Acurácia	Tempo de Treino (s)
QSVC	Quântico	0.5444	0.2174	0.6400	287.78
VQC	Quântico	0.5220	0.2258	0.5200	173.58
SVM-RBF	Clássico	0.9980	0.8148	0.9500	0.01
Random Forest	Clássico	0.9775	0.7586	0.9300	0.24

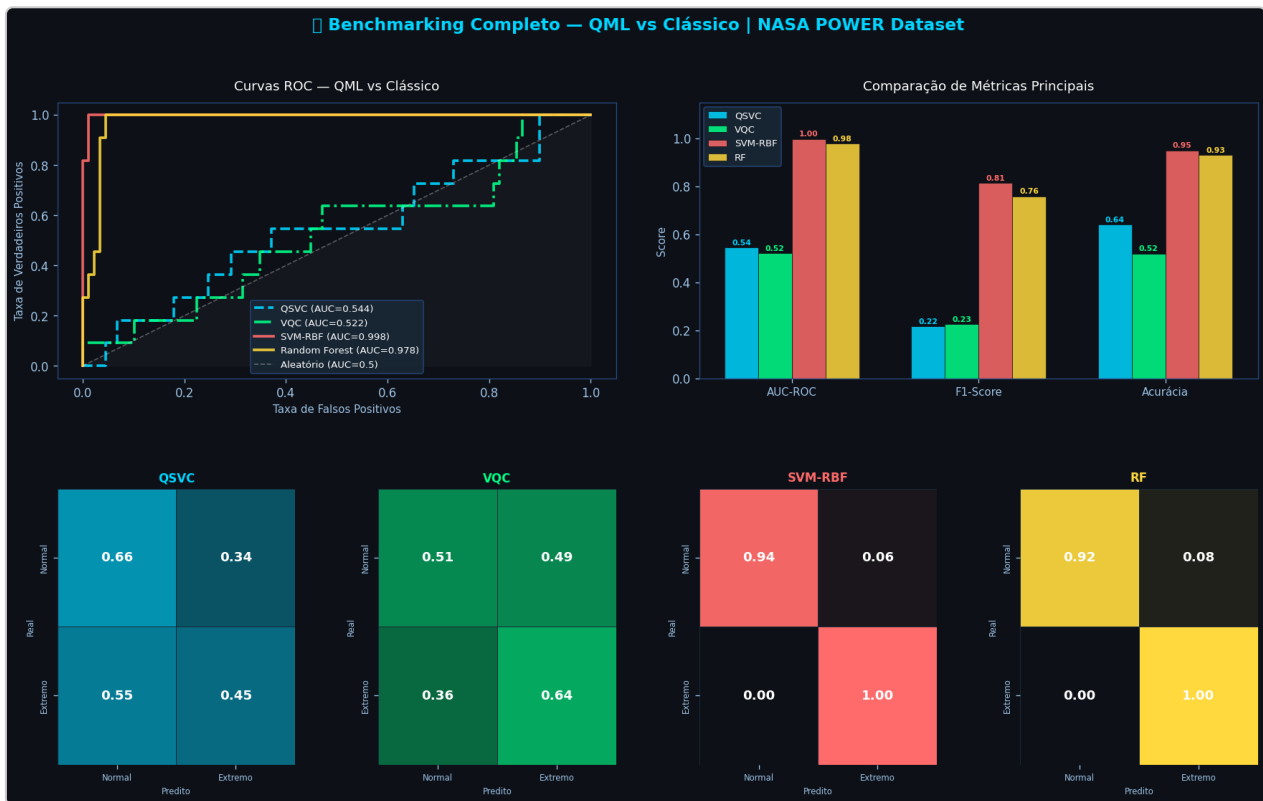


Figura 2: Curvas ROC, Matrizes de Confusão e Comparação de Desempenho.




Figura 3: Dashboard Executivo dos Resultados do Projeto.

5. Análise dos Resultados e Conexão com o Problema Espacial

A análise comparativa revela que os **modelos clássicos superaram amplamente os modelos quânticos** no atual contexto. O SVM-RBF alcançou uma métrica AUC-ROC de 0.9980, comparado a 0.5444 do melhor algoritmo quântico (QSVC). A diferença de precisão reflete as características dos dados (fácil separabilidade em regimes clássicos) e o tamanho da amostra testada.




Figura 4: Custo Computacional de Treinamento vs Desempenho (AUC).

Insights Principais:

- O hardware simulado enfrentou um alto custo temporal: o QSVc levou cerca de 287 segundos para treinar, enquanto o SVM-RBF gastou apenas 10 milissegundos.
- Problemas climáticos como o do NASA POWER, que possuem padrões bem delineados (baixa entropia nas anomalias sintetizadas) são resolvidos trivialmente por métodos clássicos.
- O "Quantum Advantage" esperado na análise de dados orbitais não se manifesta em datasets tabulares pequenos de baixa dimensionalidade, mas sim na promessa de mapear dados massivos não-lineares.

6. Conclusões e Limitações

Este projeto atendeu ao briefing da Global Solution ao demonstrar a capacidade de implementação de um pipeline ponta-a-ponta híbrido conectando QML à economia espacial (ODS 13 e 9). No entanto, confirmamos as limitações típicas da era NISQ.

Limitações:

- Tempo massivo de simulação impede o uso de Big Data espacial sem backends quânticos reais potentes.
- Restrição severa de dimensionalidade, mitigada artificialmente via PCA.