

Relatório Crítico: Implementação de Assistente RAG para Edifícios Sustentáveis

Autores: Guilherme Santos de Almeida (RM 563972) e Octávio Augusto Ramalho Brandão Pires (RM 555696)

1. Introdução e Contextualização Este relatório detalha o desenvolvimento e a validação técnica de um assistente virtual especializado em Edifícios Verdes e metodologias Net Zero (foco em energia e gestão hídrica), construído sob a arquitetura de Recuperação Aumentada por Geração (RAG). O desafio fundamental que motivou esta arquitetura é a grave limitação dos Modelos de Linguagem de Grande Escala (LLMs) generalistas no contexto da engenharia civil e arquitetura. Ao lidar com especificações técnicas do mercado brasileiro, esses modelos frequentemente falham ao fornecer diretrizes normativas precisas, gerando respostas genéricas ou alucinações perigosas. Nosso sistema propõe substituir essa incerteza por um ecossistema auditável e restrito, conectando o LLM Llama 3.2 a uma base vetorial estritamente baseada em literatura técnica verificada (normas ABNT, guias PROCEL e manuais LEED).

2. Dificuldades na Curadoria e Estruturação do Corpus A barreira inicial mais severa do projeto residiu na coleta e limpeza avançada de dados. Documentos técnicos de engenharia são densos e possuem formatações heterogêneas que quebram extratores de texto padrão. Lidamos com PDFs contendo tabelas complexas, texto em múltiplas colunas, cabeçalhos repetitivos e notas de rodapé irrelevantes para a busca semântica. Para resolver isso, desenvolvemos scripts de limpeza que padronizaram o texto e removeram quebras de linha excessivas. A segmentação (chunking) precisou ser cuidadosamente planejada: adotamos blocos com tamanho médio otimizado (cerca de 600 palavras/750 tokens) com uma sobreposição (overlap) de 100 palavras. Essa sobreposição foi crucial para garantir que requisitos normativos longos não fossem cortados pela metade, preservando o contexto completo de parágrafos que ditam, por exemplo, regras de dimensionamento de água pluvial.

3. Qualidade dos Clusters e Visualização t-SNE A etapa de geração de embeddings utilizou o modelo *paraphrase-multilingual-MiniLM-L12-v2*, altamente eficaz para o português técnico. Após a indexação no banco vetorial ChromaDB, a aplicação da redução de dimensionalidade via t-SNE revelou resultados semânticos muito consistentes. O gráfico demonstrou uma separação geométrica clara entre os chunks dedicados a "Eficiência Energética" (como normas de desempenho térmico e sistemas fotovoltaicos) e "Gestão Hídrica" (como manuais de reúso de águas cinzas). Entretanto, a visualização também indicou áreas de sobreposição ("overlap" de clusters) oriundas de documentos sobre "Certificações Gerais" (ex: Guias GBC e LEED). Como esses guias abordam energia e água em capítulos adjacentes, a proximidade vetorial era matematicamente esperada. Isso evidenciou e validou nossa decisão de anexar metadados estritos (Fonte, Categoria e

Subcategoria) a cada bloco de texto, permitindo futuras filtrações precisas na busca antes mesmo da interpretação semântica.

4. Análise de Desempenho e Cobertura do Banco Vetorial O sistema foi submetido a uma bateria de validação com 10 perguntas técnicas. O resultado foi altamente satisfatório: 8 perguntas foram respondidas com alta precisão, sempre acompanhadas da respectiva citação da norma ou relatório de origem. Nos 2 casos restantes, o sistema não possuía a resposta, mas ativou com sucesso nosso *Prompt de Sistema* restritivo, retornando a mensagem de "informação insuficiente". Essa recusa em responder é, no contexto da engenharia, um grande sucesso, pois prova que as diretrizes "Zero Alucinação" configuradas no LLM funcionaram. Concluímos que a cobertura é excelente para análises e diretrizes de projeto intermediárias, mas ainda exige a injeção de novos manuais para lidar com minúcias matemáticas de engenharia de detalhe.

5. Comparação Direta: RAG vs. LLM Puro A superioridade da arquitetura RAG ficou evidente no teste comparativo de três instâncias: "Dimensionamento de reservatórios pluviais", "Requisitos de fachadas NBR 15575" e "BEMS no Net Zero". Quando consultado sem o banco vetorial (LLM Puro), o modelo produziu textos linguisticamente corretos e plausíveis, mas sem embasamento normativo aplicável. Em um caso crítico sobre normas, o modelo puro alucinou indicando uma diretriz estrangeira não adotada no Brasil, o que em um cenário real resultaria em erro de projeto estrutural. Por outro lado, o Assistente RAG atuou como um verdadeiro consultor técnico. Ele não apenas explicou o conceito, mas apontou exatamente qual documento e critério deveriam ser seguidos para garantir conformidade. A transição foi de um sistema "conversador" para uma ferramenta de "governança técnica e auditoria".

6. Propostas de Expansão e Melhorias Futuras Apesar do êxito na prova de conceito, caso houvesse um prazo mais extenso, o sistema receberia as seguintes atualizações:

- **Busca Híbrida (Hybrid Search):** Implementar a combinação da busca vetorial pura com busca léxica (BM25). A busca por vetores entende bem o significado, mas a busca léxica é superior para encontrar termos exatos, como códigos específicos de normas ("NBR 16783").
- **OCR com Modelos de Visão (VLM):** Integração de reconhecimento ótico para ler, interpretar e estruturar as tabelas das normas, que hoje são frequentemente degradadas na extração de texto em PDF plano.
- **Memória de Conversação:** Adoção de histórico com *Buffer Memory*, permitindo ao engenheiro fazer perguntas em cadeia sobre o mesmo documento sem precisar reescrever o contexto da norma na pergunta seguinte.

7. Conclusão O desenvolvimento demonstrou cabalmente que a implementação do RAG é a solução definitiva para a IA generativa no setor de edifícios sustentáveis. A precisão técnica em projetos de eficiência hídrica e energética é inegociável, e o sistema desenvolvido entrega respostas embasadas na realidade física e legal. O projeto provou na prática que a eficácia de um LLM corporativo é apenas tão boa quanto a qualidade da curadoria dos dados estruturados pelo desenvolvedor, posicionando o RAG como o principal habilitador da automação do conhecimento na engenharia civil aplicada.

Tabela de Validação de Perguntas (Resumo)

Pergunta	RAG (Precisão)	Fonte Citada	Alucinação
1. Critérios NBR 15575	Alta	Sim	Não
2. Papel BEMS	Alta	Sim	Não
3. Equip. Hidráulicos	Alta	Sim	Não
4. Águas Cinzas	Alta	Sim	Não
5. Comissionamento	Alta	Sim	Não
6. Conflitos LEED/NBR	Média	Sim	Não
7. Módulos PV	Alta	Sim	Não
8. Sustentabilidade Hídrica	Alta	Sim	Não
9. Água Irrigação	Alta	Sim	Não
10. PROCEL Res. vs Com.	Alta	Sim	Não

∞ GS - PLN

<https://youtu.be/zKj2xNJNV10>

∞ GS_PLN_RAG_Final.ipynb